

ENERGIA EM RISCO

Análise de Dados de Continuidade
Elétrica e Previsão de Risco Regulatório

AI Talent Academy - Demo Day
Equipe 14



White Cube
A Think Group Company

EQUIPE

- Antônio Marcel Sousa
- Edivaldo Dias
- Vanessa Vilela
- Vitor Pires



AGENDA

- Introdução
- Pipeline de Dados
- Análise de Dados
- Modelo Preditivo
- Dashboard Power BI
- Conclusão





INTRODUÇÃO

Introdução

ESCOLHA DO TEMA

Falhas recorrentes no fornecimento de energia não apenas prejudicam o bem-estar e a segurança dos cidadãos como elevam os custos regulatórios das distribuidoras.

A ANEEL disponibiliza bases públicas e oficiais sobre esses eventos em todo o país.

A escolha do tema, portanto, foi motivada pelo desafio de explorar esses dados reais e construir uma solução analítica para apoio à tomada de decisão.



CONTEXTUALIZAÇÃO

Sob a regulação da ANEEL, a qualidade e a regularidade do fornecimento de energia elétrica no Brasil são monitoradas através de dois indicadores fundamentais:



PROBLEMAS

- Atuação reativa e não preventiva, com a identificação de falhas apenas no fim do ciclo regulatório.
- Custos financeiros imediatos com compensações a consumidores e desgaste na reputação da concessionária.
- Volume massivo de ocorrências descentralizadas e sem padronização limitando a visão operacional e as estratégias de negócio.



Introdução

OBJETIVO

Desenvolver uma solução integrada de Dados e Machine Learning para analisar o histórico do DEC e FEC e antecipar o risco de transgressão regulatória no período seguinte.




BASE DE DADOS

- Dados públicos disponibilizados no Portal da ANEEL.
- 5 bases utilizadas ao todo num período de cinco anos (2021 a 2025):
 - Indicadores Coletivos de Continuidade (DEC/FEC)
 - Interrupções de Energia Elétrica nas Redes de Distribuição
 - Limites Regulatórios
 - Atributos de Conjuntos
 - Indicadores por Município




- Links: [Repositório GitHub](#) | [Kanban](#)



Introdução


TECNOLOGIAS






PIPELINE DE DADOS

PIPELINE ELT



- O projeto implementa um pipeline ELT local sob o paradigma da arquitetura medalhão (camadas Bronze, Silver e Gold) com o objetivo de transformar dados brutos públicos da ANEEL em tabelas prontas para consumo analítico.
- Etapas de Extração, Transformação e Processamento dos dados, além de quality gates que validam cada transição entre camadas com o propósito de garantir a integridade e confiabilidade dos dados processados.


PIPELINE ELT



- **Camada Bronze:** Extração e armazenamento local dos dados brutos do Portal da ANEEL.
- **Camada Silver:** Limpeza, tipagem, padronização temporal e recorte do período de análise (2021 a 2025) por meio de consultas SQL, usando DuckDB.
- **Camada Gold:** Geração das tabelas fato e dimensões em Parquet, com cálculo de DEC, FEC, limites e transgressões.
- **Consumo:** Modelo dimensional em Star Schema (2 tabelas fato e 7 dimensões) prontas para consumo analítico.
- **Quality Gate:** Etapa de validação da integridade dos dados entre camadas.

Pipeline de Dados

STAR SCHEMA






ANÁLISE DE DADOS





COMPREENSÃO DOS DADOS

- Cerca de ~0,2% de dados nulos na tabela fato continuidade, concentrada em limites regulatórios, e 0% na tabela fato causa mensal.
- Tabelas dimensionais apresentaram 0% de valores ausentes.
- Indicadores e interrupções possuem concentração próxima de zero e caudas longas.




ANÁLISE EXPLORATÓRIA DE DADOS

- Ciclos anuais bem definidos em DEC e FEC, com vales acentuados no meio do ano e elevações entre outubro e março.
- O FEC possui ultrapassagem parcialmente nula em todo o período analisado.
- O DEC possui ciclos de ultrapassagem de limites anuais variando entre agosto e dezembro.




ANÁLISE EXPLORATÓRIA DE DADOS

Participação Regional no Total de DEC




Participação Regional no Total de FEC



- O Nordeste responde pela maior fatia do tempo total sem energia e quase um quarto das ocorrências.
- O Sudeste lidera o volume acumulado de interrupções e representa 22,9% do DEC.
- A região Norte responde por quase um quinto do impacto total do país, confirmando maior vulnerabilidade da malha e tempos médios de restabelecimento mais longos.

HIPÓTESES

Hipótese 01: Os conjuntos com histórico mais frequente de transgressões de DEC/FEC apresentam maior probabilidade de ultrapassar o limite no período seguinte.




- **Metodologia:** Agregação por conjunto, indicador, período, região, distribuidora e tipo de interrupção com aplicação de funções temporais para comparar histórico e período seguinte. O risco foi obtido pela proporção de transgressões futuras em cada faixa (Risco seguinte (%) = média da transgressão do período seguinte × 100).

Hipótese Confirmada! Para o DEC, a taxa de transgressão saltou de 0,03% para 21,43%, confirmando forte inércia operacional e reincidência no sistema.

HIPÓTESES


Hipótese 02: As interrupções não programadas apresentam maior contribuição para o impacto operacional e para a variação do DEC do que interrupções programadas.



Hipótese Confirmada!

As interrupções não programadas concentram a quase totalidade do impacto operacional e da formação da duração equivalente de interrupção (DEC).

Hipótese 03: Determinados meses, regiões ou distribuidoras concentram níveis maiores de DEC, FEC ou ultrapassagens regulatórias.



Hipótese Confirmada!

Existem concentrações regionais e sazonais nítidas, com destaque para a vulnerabilidade crítica da região Centro-Oeste durante a transição do período seco para a estação chuvosa.

PRINCIPAIS INSIGHTS

- Conjuntos com histórico reincidente apresentam risco até 700 vezes maior de nova violação (0,03% → 21,43%), comprovando que o passado recente é o preditor mais forte para novas falhas.
- O pico de infrações concentra-se no início do período de chuvoso no Centro-Oeste (setembro a novembro, ápice em outubro com 0,95%). Já regiões como o Sudeste sustentam índices controlados o ano inteiro.
- As distribuições das durações e excessos mostram que o descumprimento de limites é um evento raro no período analisado.



MODELO PREDITIVO

ESPECIFICAÇÕES DO MODELO

- **Período:** 5 anos (2021 a 2025)
- **Escopo:** Todas as regiões do Brasil
- **Variável Alvo:** *UltrapassouLimite*
 - Compara *VlrIndicador* (VlrIndiceEnviado) com *VlrLimite*. Quando o indicador supera o limite, recebe 1; caso contrário, recebe 0.
 - Em seguida, a função LEAD do SQL desloca essa informação para o próximo período, formando o alvo utilizado na previsão. Uma condição é que a janela futura é gerada somente se o conjunto tiver continuidade de dados mês a mês.

Exemplo:

Mês	Transgressão atual	LEAD
Jan	0	1
Fev	1	0
Mar	0	—

PREPARAÇÃO DE DADOS

- **Filtro de Integridade Temporal:** A base de ~367 mil linhas se deve pela presença observações com duplicidade de chaves e para assegurar a integridade das séries históricas contínuas.
- **Engenharia de Atributos:** Variáveis temporais acumuladas (lags, médias móveis e reincidências), estimativa de porte e sazonalidade.
- **Pré-Processamento:** Codificação cíclica de datas e One-Hot Encoding para atributos categóricos.
- **Divisão dos Dados:** Divisão por período para evitar vazamento temporal.

Partição	Período	Observações	% base	Transgressões	% Transgressões	Atributos
Treino	2021 a 2023	223.184	61%	70	0.03%	129
Validação	2024	75.072	20%	14	0.02%	129
Teste	2025	69.026	19%	6	0.01%	129

MÉTRICAS E MODELOS CANDIDATOS

Métricas escolhidas com base no desbalanceamento das classes. A acurácia não foi escolhida devido à raridade das transgressões.

Precisão	Recall	F1-Score	ROC-AUC	PR-AUC	Matriz de Confusão
A proporção de verdadeiros positivos entre todas as instâncias que o modelo classificou como positivo	A proporção de verdadeiros positivos que foram identificadas com sucesso pelo modelo	A média harmônica entre Precisão e Recall	A capacidade do modelo de distinguir a classe positiva da negativa em todos os limiares possíveis	A capacidade discriminatória focada exclusivamente na classe minoritária, ideal para desbalanceamento extremo	O mapeamento das predições em Verdadeiros Negativos (TN), Falsos Positivos (FP), Falsos Negativos (FN) e Verdadeiros Positivos (TP).


Modelos escolhidos com base na capacidade de capturar não linearidades e baixo custo computacional.

Regressão Logística	ExtraTrees Classifier	LightGBM	XGBoost	CatBoost
Modelo linear. Referência interpretável e base de comparação	Ensemble por Bagging. Captura interações não lineares com menor variância do que árvores tradicionais.	Gradient Boosting. Alta velocidade e performance em dados tabulares com classe rara.	Gradient Boosting. Forte capacidade de modelagem de padrões complexos com regularização.	Gradient Boosting. Robustez em dados tabulares e controle de viés com tratamento do desbalanceamento.

VALIDAÇÃO CRUZADA TEMPORAL

- Validação Cruzada Temporal com **TimeSeriesSplit** nos dados de treino.
- A otimização foi guiada por **PR-AUC**, a métrica mais adequada para dados desbalanceados.
- O **XGBoost** teve o maior PR-AUC isolado pós-tuning, mas com maior custo computacional; **Regressão Logística** e **LightGBM** foram os mais rápidos.
- **ExtraTree** e **CatBoost** geraram maiores custos computacionais, porém desempenho inferior.


Impacto da Otimização: Comparativo Pré vs. Pós-Tuning



COMPARATIVO DE MODELOS

- Definição da meta mínima de 60% de Recall (9 de 14 acertos nos dados de validação) para superar o limiar arbitrário de 50%.
- Regressão Logística, XGBoost e Extra Trees** atingiram 64,3% de Recall (9/14 positivos), com um volume controlado de falsos positivos.
- CatBoost e LightGBM** entregaram 85.7% de Recall (12/14 positivos), porém com alto volume de falsos positivos.

Comparativo após ajuste do limiar operacional — Recall mínimo de 60%





Modelo Preditivo

MODELO VENCEDOR

Critério: Maior PR-AUC entre modelos com Recall mínimo de 60% na Validação

Modelo Vencedor: Regressão Logística	
Métricas (Teste Cego):	
Precisão	0,035%
Recall	50,0%
F1-Score	0,07%
ROC-AUC	0,8754
PR-AUC	0,0006
Limiar Operacional	23,84%
Observações Avaliadas	69.026
Total de Alertas	8.578



Principais Coeficientes do modelo: Percentual do limite atingido e histórico de DEC acumulado foram os maiores pesos positivos para predição de risco.



DASHBOARD POWER BI

Projeto AI Talent Academy



Agência Nacional de Energia Elétrica

Energia em Risco

Indicadores de continuidade, causas das interrupções e
predição de risco



Visão
Executiva



Diagnóstico das
Interrupções



Predição
de Risco



White Cube
a Data Intelligence

[Link Dashboard Power BI](#)

CONCLUSÃO



Conclusão

CONSIDERAÇÕES FINAIS

- A solução transforma dados públicos da ANEEL em informação operacional e preditiva.
- O pipeline proporciona rastreabilidade, padronização e reutilização dos dados.
- Como melhorias futuras para o modelo é sugerida a incorporação de dados climáticos para refinar as causas das interrupções e a setorização do modelo por região.





OBRIGADO(A)!